Análisis del Comportamiento de los Clientes a través de Métodos de Topología y Aprendizaje Automático

Mauricio Valencia - A01234397

1 de mayo de 2025

Resumen

En este trabajo se exploran los hábitos de gasto con tarjetas de crédito en la India en función de sus características demográficas (género, ciudad, tipo de tarjeta, tipo de gasto) y su monto de compra. Se utilizaron varios métodos de Análisis Topológico de Datos (TDA), junto con técnicas tradicionales de Aprendizaje Automático (clustering) para segmentar y analizar patrones en los datos. Se discuten los resultados obtenidos, la relevancia de los algoritmos utilizados, y cómo estos pueden influir en decisiones comerciales como la segmentación de clientes.

1. Introducción

El análisis del comportamiento de los clientes es crucial para las empresas, ya que les permite tomar decisiones informadas sobre sus estrategias comerciales. En este contexto, la segmentación de clientes y el análisis de sus patrones de compra son fundamentales. Según [Cooper,] aunque los resultados pueden tener alta varianza, el uso de técnicas de Análisis Topológico de Datos (TDA) puede ser útil.

1.1. Preguntas de Investigación

Las principales preguntas de investigación que se abordan en este estudio son:

- ¿¿Existen patrones no lineales o estructuras complejas en el comportamiento de compra según el género, tipo de tarjeta, tipo de gasto y

ciudad de los clientes, que no puedan ser capturados por técnicas tradicionales de clustering?

- ¿Cómo se segmentan los clientes según su comportamiento de compra (Amount) en función de sus características demográficas?

En la literatura se muestra que técnicas tradicionales de clustering (como KMeans) a menudo no son suficientes para capturar la complejidad de los datos. Estudios recientes sugieren que el uso de TDA, específicamente de análisis de persistencia y mappers, puede ofrecer ventajas al revelar relaciones topológicas ocultas. [Panagopoulos, 2022].

1.2. Objetivo e Hipótesis

El objetivo principal de este estudio es explorar cómo las características demográficas de los clientes afectan su comportamiento de compra, utilizando tanto métodos de clustering clásicos como técnicas avanzadas de TDA. Se plantea la siguiente hipótesis:

Hipótesis: El comportamiento de compra de los clientes, representado por el monto gastado (Amount), puede ser mejor comprendido mediante la utilización de TDA, ya que los patrones subyacentes en los datos son no lineales y complejos. Así mismo, las compras mas extremas (se compro mucho o muy poco) serán las que tendrán características topológicas mas diferentes y serán fáciles de separar e identificar.

2. Metodología

2.1. Procesamiento de la Base de Datos

La base de datos utilizada contiene información sobre las compras de los clientes, incluyendo las siguientes columnas: `City`, `Gender`, `Card Type`, `Exp Type`, y `Amount`. Se realizaron los siguientes pasos de preprocesamiento:

- **Codificación de variables categóricas:** Se aplicó Target Encoding a las variables `City`, `Card Type`, `Exp Type`, y `Gender`.
- **Normalización:** Se normalizaron las variables utilizando el `StandardScaler` para garantizar que todas las variables tuvieran la misma escala.
- **Selección de datos:** Para realizar el análisis de persistencia, se seleccionó una muestra aleatoria de 500 datos.

2.2. Análisis Estadístico Relevante

Se realizaron análisis estadísticos exploratorios, incluyendo:

- **Distribución de la variable `Amount`:** Se visualizó mediante histogramas para identificar su distribución.
- **Distribución de valores únicos:** Se analizaron los posibles valores que podía adquirir una variable y cuantos había de cada uno.

2.3. Algoritmos de TDA Utilizados

Para el análisis topológico, se utilizó el algoritmo de **Ripser** para calcular los diagramas de persistencia en las dimensiones 0, 1 y 2. Este algoritmo es relevante para nuestro problema porque permite identificar la estructura topológica de los datos, lo cual puede ser útil para detectar patrones no evidentes en el espacio de características. La elección de Ripser se basó en su eficiencia en la construcción de complejos simpliciales y la visualización de los resultados mediante diagramas de persistencia.

Además, se utilizó el algoritmo de **Mapper** para proyectar los datos en una menor dimensión y en base a eso, hacer una clusterización y poder hacer el grafo Mapper. Se eligió usar este algoritmo, porque a través del grafo se pueden mostrar características topológicas que de otra manera podrían pasar desapercibidas.

2.4. Algoritmo de Aprendizaje Automático

Se utilizó el algoritmo de **KMeans** en la clusterización para la construcción del grafo Mapper.

3. Resultados

El diagrama de persistencia mostró que en H_0 existen varias características relevantes, aunque no muchas, mientras que en H_1, vemos longitudes muy pequeñas. Lo que sugiere que los datos no tienen estructuras topológicas complejas, esto iría en contra de nuestra hipótesis inicial de que los patrones subyacentes en los datos son no lineales y complejos.

Del Kmapper obtuvimos el grafo de la imagen. El color es el que indica el gasto y como pudimos ver en los histogramas de arriba, la mayoría de los datos están entre 0 y 1, con unos cuantos que llegan hasta 8.

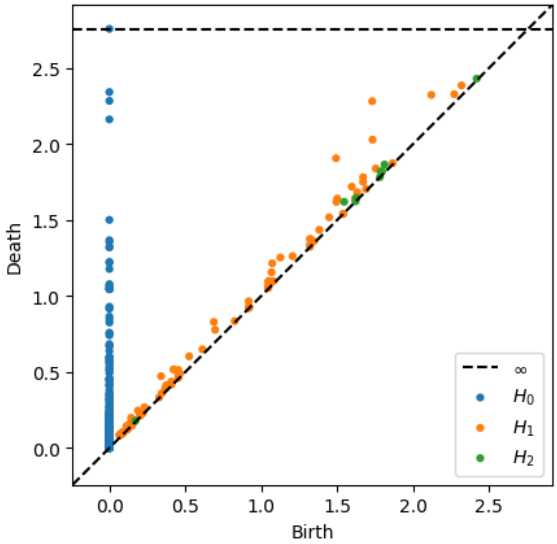

Figura 1: Diagrama de persistencia en H0, H1 y H2

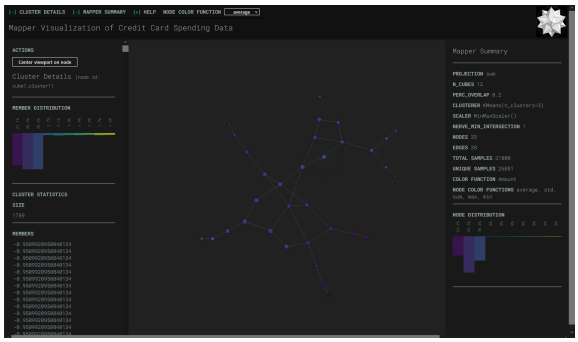

Figura 2: Grafo Mapper

La estructura general del grafo es una cruz; los brazos horizontales tienen mas valores cercanos a 1, mientras que los brazos verticales tienen mas valores cercanos a 0. En general están bastante mezclados, pero tienden mas hacia 1 u otro valor. Esto también indica que no hay mucha diferencia en las características de los clusters.

Esto podría ser, por los valores de amount que van hasta 8, si eliminaramos esas entradas, el análisis sería mas sensible a cambios dentro de 0 y 1, pero consideré relevante mantener esas entradas, ya que por su naturaleza pudieron haber tenido características diferentes.

Gracias a esto podemos decir que la segmentación de los clientes se haría de3 acuerdo a una ligera pero significativa diferencia en los hábitos de consu-

mo de personas que gastan (de acuerdo a los valores del primer histograma) cantidades cercanas a 300,000 y personas que gastan cantidades cercanas a 0. Estos serían los extremos en cuanto a diferencias de características. Por otro lado, quienes gastan significativamente mas de 300,000, por ejemplo alrededor de 1,000,000 tienen características mas acordes al consumidor promedio.

4. Conclusiones

Los resultados fueron lo contrario a lo originalmente propuesto en la hipótesis:

- Para esta base de datos, puede ser igual de efectivo hacer uso de aprendizaje automático tradicional, como TDA para comprender el gasto y comportamiento de los clientes.
- Las compras con los valores mas extremos, no tuvieron las características topológicas mas diferentes y no es fácil separarlas en su propio cluster.

Aún así, se pudieron contestar las 2 preguntas de investigación, la primera con el análisis de persistencia y la segunda con el grafo Mapper.

Referencias

[Cooper,] Cooper, J. Topological analysis of credit data: Preliminary findings.

[Panagopoulos, 2022] Panagopoulos, D. (2022). Topological data analysis and clustering.